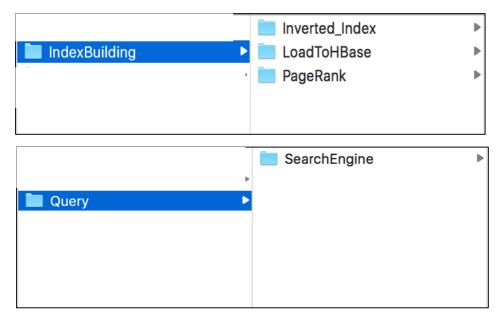
# CloudProgramming HW3-Search Engine Report

學號姓名:101062231 林展逸

### 1. File

共有兩個部分,第一部分是 IndexBuilding,第二部分是 Query



### 2. Instruction

首先是 IndexBuilding

(1) Inverted\_Index:

Compile: sh compile.sh

Run: sh run.sh

(從 executive.sh 中更改 input file)

(2) PageRank:

Run:

spark-submit --class PageRankSpark --num-executors 30 target/scala-2.10/page-rank-spark\_2.10-1.0.jar input(ex:hdfs:///shared/HW2/sample-in/input-100M)

(3) LoadToHBase

Compile: sh compile.sh Run: sh execute.sh

再來是 Query 的部分

(4) SearchEngine (change the input file in the code SearchEngine.java)

Compile: sh compile.sh

Run: sh run.sh

Search: 輸入 => search "XXX and XXX"

Ex: search "cat and dog"

## 3. Implementation

(1) 首先是 HBase 的 schema。

HBase 中共有兩個 Table,分是"s101062231:Inverted","s101062231:PageRank"

### s101062231:Inverted

word	df	invertedInfo
gypsy	2	Growel's 101 <div>1.0<div>[85920942]<maindiv>Wikipedia:WikiProject Spam/LinkReports/sydroger.blogspot.com<div>2.0<div>[66489813,66490285]</div></div></maindiv></div></div>
XXX	df	PageName1 <div>tf<div>[offset]<maindiv>PageName2<div>tf<div>[offset]<maindiv></maindiv></div></div></maindiv></div></div>

#### s101062231:PageRank

page	pageRank
Page1	x.xxxxxxxx
Page2	x.xxxxxxxx

### (2) 再來是 Query 的步驟

我們假設使用者搜尋"cat"、"dog"兩個字

先從 s101062231:Inverted 取出這兩個字的 df 及 invertedInfo。

再來先對照這兩個字的 pageList,找出同時包含"cat"、"dog"的 Page,同時算出他們的 TFIDF 值,如果同時包含"cat"、"dog",則將 TFIDF 相加。 另外 offset 採 append 上去的方式。

接著取出 TFIDF 最高的 10 個 Page。這 10 個 Page 表示與"cat"、"dog"最 具相關性。

接著從 <u>s101062231:PageRank</u> 中取出這 10 個 Page 的 PageRank。

再來針對 pageRank 在從高到低排序一次,從最 popular 到最不 popular。

(3) 最後從剛剛紀錄的 offset 中取前三個 offset,把 fragment 印出來。

Search:

Sea